

偏导数与全微分

引言

在多元微积分里，**偏导数**和**全微分**是一对孪生概念：前者告诉你当**某一条坐标轴**上微移时函数的瞬时变化率，后者把所有坐标方向的信息**整合成一条“总账”**，给出最精确的一阶线性近似。为了让概念扎根，我们用 **Why → What → How → How Good** 的四步框架来“拆”它们。

1 Why —— 为什么需要它们？

典型情境	为什么少不了偏导数 / 全微分
工程调参 ：发动机效率 $E(p, T)$ 随压力 p 、温度 T 变化	想知道“单独提高 1 K 温度能带来多少效率提升？”→ 用 $\partial E / \partial T$ ；想估计“两者各变一点”后的整体变化 → 用全微分 dE 。
数据敏感度 ：模型输出 $f(\mathbf{x})$ 对输入误差的放大	需要量化“哪一维更敏感”与“合成误差的首阶估计”。
最优化 ：在 \mathbb{R}^n 中找极值	梯度 ∇f （偏导数打包）= “爬坡指南针”；全微分=切平面，用来验证可微性与泰勒展开。
坐标变换 ：极坐标、球坐标、机器人的关节坐标	链式法则写成 $df = \nabla f \cdot d\mathbf{r}$ 才能快速“换账”。

2 What —— 概念到底是什么？

2.1 偏导数 (Partial Derivative)

对二元函数举例：

$$\frac{\partial f}{\partial x}(x_0, y_0) = \lim_{h \rightarrow 0} \frac{f(x_0 + h, y_0) - f(x_0, y_0)}{h}.$$

- 几何意涵**：沿 x 轴方向作水平切片，看到的是一条单变量曲线；偏导就是那条曲线在点 (x_0, y_0) 处的斜率。
- 向量视角**：把全部偏导排成列就得到了 **梯度**

$$\nabla f(x_0, y_0) = \left(\frac{\partial f}{\partial x}, \frac{\partial f}{\partial y} \right).$$

2.2 全微分 (Total Differential)

若 f 在 \mathbf{x}_0 处可微，则存在线性映射 $Df(\mathbf{x}_0) : \mathbb{R}^n \rightarrow \mathbb{R}$ 使

$$f(\mathbf{x}_0 + \mathbf{h}) = f(\mathbf{x}_0) + Df(\mathbf{x}_0)[\mathbf{h}] + o(\|\mathbf{h}\|).$$

写成“坐标 + 形象”版本：

$$df = \sum_{i=1}^n \frac{\partial f}{\partial x_i} dx_i = \nabla f \cdot d\mathbf{x}$$

它就是 **最优一次线性近似** 的“公式化身”； dx_i 是“你愿意怎样小动”的自由度，全微分把每一维的影响加权并求和。

3 How —— 如何计算与运用？

3.1 一步步算

1. 先算所有偏导。
2. 组装梯度 ∇f 。
3. 替换 dx_i 得到全微分。

示例 $f(x, y, z) = x^2yz + \sin(xz)$

$$\begin{aligned} &> f_x = 2xyz + z \cos(xz), \quad > f_y = x^2z, \quad > f_z = x^2y + x \cos(xz) \\ &> \Rightarrow df = (2xyz + z \cos xz) dx + x^2z dy + (x^2y + x \cos xz) dz. > \end{aligned}$$

3.2 常用操作

任务	做法	说明
误差传播	$\sigma_f^2 \approx \sum_i \left(\frac{\partial f}{\partial x_i} \sigma_{x_i} \right)^2$	把全微分看作随机增量的线性组合；前提是误差小且独立。
链式法则（复合函数）	若 $u = g(\mathbf{x})$, $y = f(u)$	先算 du , 再 $dy = f'(u) du$ 。
隐函数微分	方程 $F(x, y) = 0$	取全微分 $F_x dx + F_y dy = 0 \rightarrow \frac{dy}{dx} = -\frac{F_x}{F_y}$ 。
切平面/线性化	$L(\mathbf{x}) = f(\mathbf{x}_0) + \nabla f(\mathbf{x}_0) \cdot (\mathbf{x} - \mathbf{x}_0)$	把全微分写在 $\mathbf{h} = \mathbf{x} - \mathbf{x}_0$ 上即可。

4 How Good —— 线性近似到底有多好？

1. 误差阶数

$$f(\mathbf{x}_0 + \mathbf{h}) = f(\mathbf{x}_0) + \nabla f \cdot \mathbf{h} + \underbrace{\frac{1}{2} \mathbf{h}^\top H_f(\mathbf{x}_0) \mathbf{h}}_{\text{二阶项}} + o(\|\mathbf{h}\|^2),$$

其中 H_f 是 Hessian。

- **结论**：只要 $\|\mathbf{h}\|$ 足够小，遗漏的部分是 **二阶无穷小**。

2. 误差上界（均匀 Lipschitz）

若梯度连续且有界 $\|\nabla f\| \leq M$ ，则

$$|f(\mathbf{x}_0 + \mathbf{h}) - f(\mathbf{x}_0) - \nabla f \cdot \mathbf{h}| \leq \frac{M}{2} \|\mathbf{h}\|^2.$$

3. 偏导数存在≠可微

- 经典反例： $f(x, y) = \frac{|xy|}{x^2+y^2}$ 在 $(0, 0)$ 处虽有全部偏导，却不可微。
- 检验标准：偏导连续 \Rightarrow 一定可微；只给存在不够。

5 联系 vs. 区别（一句话版）

偏导数 = 按坐标轴“局部单项考试”；

全微分 = 把所有考试成绩按权重汇总，变成一份“总评估 + 线性预测”。

6 常见误区

1. **把 df 当作“具体数值”**

df 是线性算子，只有给定一组 (dx_1, \dots, dx_n) 后才会产出数字。

2. **忽视“高阶小量”**

$\Delta f \approx df$ 不是等号；差别正是一阶近似的误差。

3. **梯度方向**

∇f 指向最速增方向，不是“切线方向”。切向量在梯度的正交子空间里。

7 总结·回味

- **Why**：在多变量世界里量化“单向敏感度”与“整体线性变动”，离不开这两个概念。
- **What**：偏导数 = 单轴极限斜率；全微分 = 梯度·微位移 = 最佳一次线性映射。
- **How**：先求偏导→组梯度→套公式；以误差传播、链式法则、隐函数、优化为典型舞台。
- **How Good**：误差为 $O(\|\mathbf{h}\|^2)$ ，梯度连续即可确保“好”；若仅有偏导则仍需警惕不可微陷阱。

掌握了“单项考试 + 总评估”的思路，你就能从任何角度“拨动”变量，立即评估函数的首阶响应，并确信自己的估算有多靠谱。