

多元函数一阶微分形式不变性

下面用 Why → What → How → How Good 四层框架，把「多元函数的一阶微分」与它的「形式不变性」两个紧密相关的概念层层剖开，帮助你真正“吃透”它们。

1 Why：为什么要关心一阶微分及其形式不变性？

视角	动机
数学内部	1. 统一语言 ：把割线极限、雅可比矩阵、链式法则、隐函数定理等零散技巧收编到“微分”这一句式中，极大降低理论复杂度。 2. 坐标自由 ：真正的几何/物理定律不依赖选取的坐标。一阶微分是最早出现、最简单体现“坐标无关性”的对象。
应用外部	1. 误差估计 ：任何多元拟合、灵敏度分析都离不开“一阶近似 + 误差阶 $o(\ h\)$ ”。 2. 物理建模 ：保留形式不变，确保公式在极坐标/球坐标/广义坐标里都能直接使用（例如流体动力学中的质量守恒式 $d\rho + \rho \nabla \cdot \mathbf{v} dt = 0$ ）。

一句话：如果没有“形式不变性”，微积分在换一套变量时就得推倒重来——等同于失去把知识模块化、可移植的能力。

2 What：概念本身是什么？

1. 多元函数的一阶微分

对 $f: \mathbb{R}^n \rightarrow \mathbb{R}$ ，在点 x 的一阶微分（也叫**全微分**或**第一微分形式**）是线性映射

$$df_x: \mathbb{R}^n \rightarrow \mathbb{R}, \quad df_x(h) = \sum_{i=1}^n \frac{\partial f}{\partial x_i}(x) h_i.$$

把它写成“系数 × 微分量”的外观

$$df = \sum_{i=1}^n f_{x_i} dx_i$$

就是一阶微分的**局部坐标表达**。

2. 形式不变性

同一个对象在不同坐标系/变量选取下有不同坐标表达，但内容（映射本身）不变：

$$df = \sum_i f_{x_i} dx_i = \sum_j f_{y_j} dy_j \quad (\text{经链式法则})$$

这说明 df 是**坐标无关的 1-形式**，正因为它代表了点 x 上的一个线性泛函，而线性泛函天然“只看向量本身，不看它如何被数字坐标描述”。

3 How：形式不变性如何成立？怎么用？

3.1 证明思路（核心只用链式法则）

1. 写出 f 先在旧坐标再在新坐标中的复合: $\tilde{f}(\mathbf{y}) = f(\mathbf{x}(\mathbf{y}))$.
2. 对 \tilde{f} 求全微分:

$$d\tilde{f} = \sum_i \frac{\partial f}{\partial x_i} dx_i = \sum_{i,j} \frac{\partial f}{\partial x_i} \frac{\partial x_i}{\partial y_j} dy_j.$$

3. 识别系数 $f_{y_j} := \sum_i f_{x_i} \frac{\partial x_i}{\partial y_j}$, 便得到

$$\mathrm{d}f = \mathrm{d}\tilde{f} = \sum_j f_{y_j} \mathrm{d}y_j.$$

这恰是“一阶微分公式在两套坐标里长相不同但值相同”的形式化。

隐函数定理视角：若把某些 x_i 当作隐变量， f 的微分照样用同一行公式拿到；过程不需区分显式/隐式依赖，这正是一阶微分在实际运算中“好用”的来源。

3.2 实战示例

场景	具体操作	不变性体现
最速下降 (Gradient Descent)	更新步方向取 $-df^\sharp$ (\sharp 为指标升高, 将 1-形式变向量)。	坐标换了、度量变了, df 仍是同一个 1-形式, 只需随新度量再“升指标”就行。
误差传播 (Error Propagation)	不确定度 $\sigma_f^2 = df(\Sigma_x)df^\top$ 。	任何变量重标定都自动通过雅可比矩阵更新 Σ_x , 而公式本体 df 不动。
守恒律 (物理论)	质量守恒用 $d\rho + \rho \operatorname{div} \mathbf{v} dt = 0$ 。	变到旋转坐标或曲线坐标, $d\rho$ 仍旧是对标量场 ρ 的外微分。

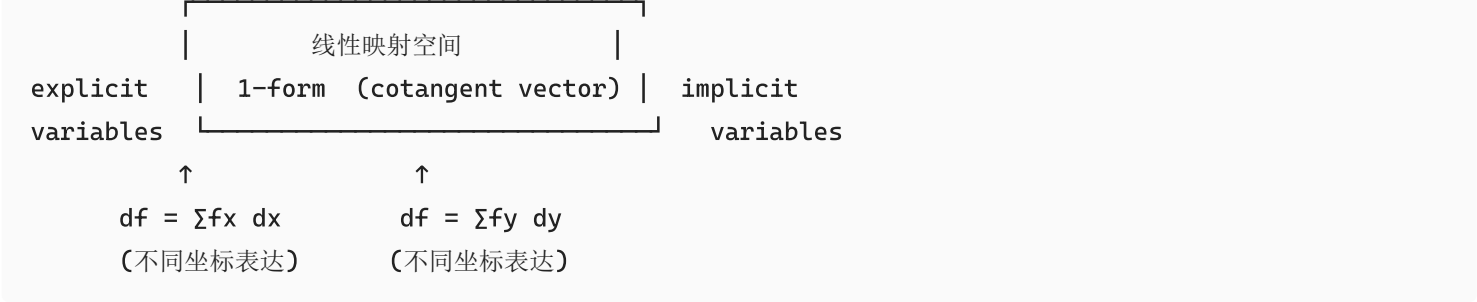
4 How Good: 这一层抽象有多好? 有什么边界?

维度	优点	可能的局限/误区
概念层面	→ 彻底统一偏导、全导、链式法则； → 为高阶微分、微分形式、流形上的外微分打基础。	如果停留在“把符号凑成式子”层面，忽视其线性映射本质，容易在高阶或非线性坐标变换里出错（如把 $d(df)$ 当 d^2f 用）。
计算层面	→ 在任意坐标、甚至隐变量模型下都直接套公式； → 与线性代数/矩阵库天然兼容 ($df \leftrightarrow$ 梯度向量)。	当所处空间带约束（流形嵌入）或度量异常（洛伦兹度量）时，需要将“升指标”/“降指标”步骤分清，否则数值梯度不再是 df^\sharp 。
工程实现	→ 自动微分框架 (PyTorch、JAX) 内部正是把“张量图”编译成微分算子并利用链式法则自动保持不变。	性能开销：在深网训练里，如果对每层都保留完整 1-形式对象，显存爆炸。工程上会用后向传播把它折叠为标量对参数的梯度。

顺手给出一张“心智地图”

coordinate change





一句话收束

多元函数的一阶微分，是把函数在一点附近“拉直”成一个线性泛函；“形式不变性”保证了这根“绳子”无论在什么坐标系里都是同一根——你只是在看它的不同刻度标签而已。当你真正把它当作对象而非公式来使用时，微积分的链式复杂度与坐标尴尬都会瞬间消失。